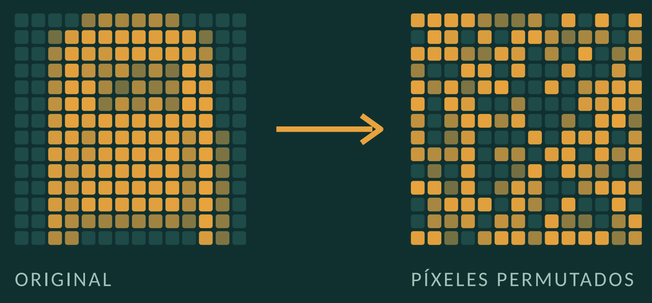
REDES DE NEURONAS · MÁSTER EN IA APLICADA · UC3M

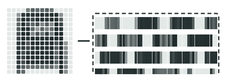
Sesgos inductivos: ¿cuándo importa la arquitectura?

Alejandro Riego Velasco · Javier Aceituno Monja · Santiago Herron Mulet · Rodrigo Toldos Frutos



La misma prenda, ordenada y con sus píxeles desordenados. Para el MLP es el mismo problema; para la CNN, no.

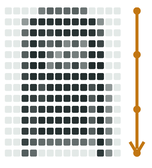
Un sesgo inductivo ayuda cuando los datos tienen la estructura que supone, y estorba cuando no la tienen.



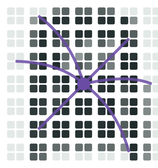
MLP
Sin sesgo espacial: ve un vector de 784 valores.
89,3 ± 0,1 % test



CNN
Localidad: el mismo filtro 3×3 recorre toda la imagen.
92,0 ± 0,2 % test



LSTM
Secuencia: lee la imagen fila a fila, de arriba abajo.
90,5 ± 0,1 % test



Transformer
Parches 4×4 que se relacionan por atención.
88,4 ± 0,4 % test

Datos. Fashion-MNIST: 55 000 imágenes de entrenamiento, 5 000 de validación y 10 000 de test. **Modelos.** Unos 100 000 parámetros cada uno. **Entrenamiento.** El mismo para los cuatro: AdamW, 8 000 pasos, learning rate elegido por modelo en validación y el mejor punto en validación. **Estadística.** 5 semillas por condición, media ± σ e intervalo al 95 % (Welch). **Predicciones** escritas antes de experimentar y no modificadas.

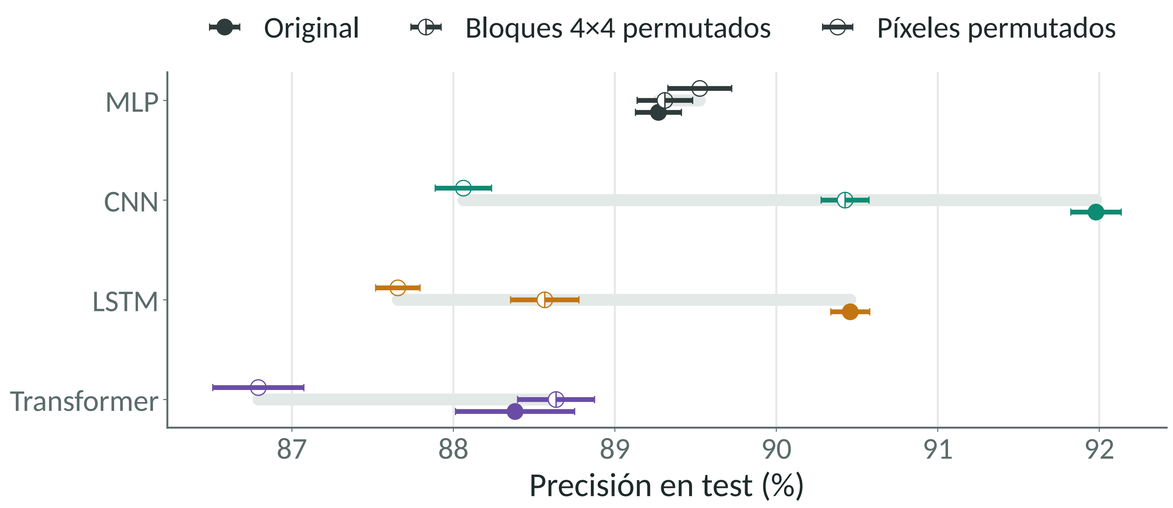


Qué cambiamos en cada hipótesis. En H1 y H4 se reentrena; en H3 se evalúan los modelos ya entrenados.

H1 ESTRUCTURA DE LA ENTRADA — CONFIRMADA

«La ventaja de una arquitectura con sesgo inductivo desaparece si se destruye la estructura de la entrada.»

+2,7 → −1,5 puntos de ventaja de la CNN sobre el MLP, con la imagen original y con los píxeles permutados.

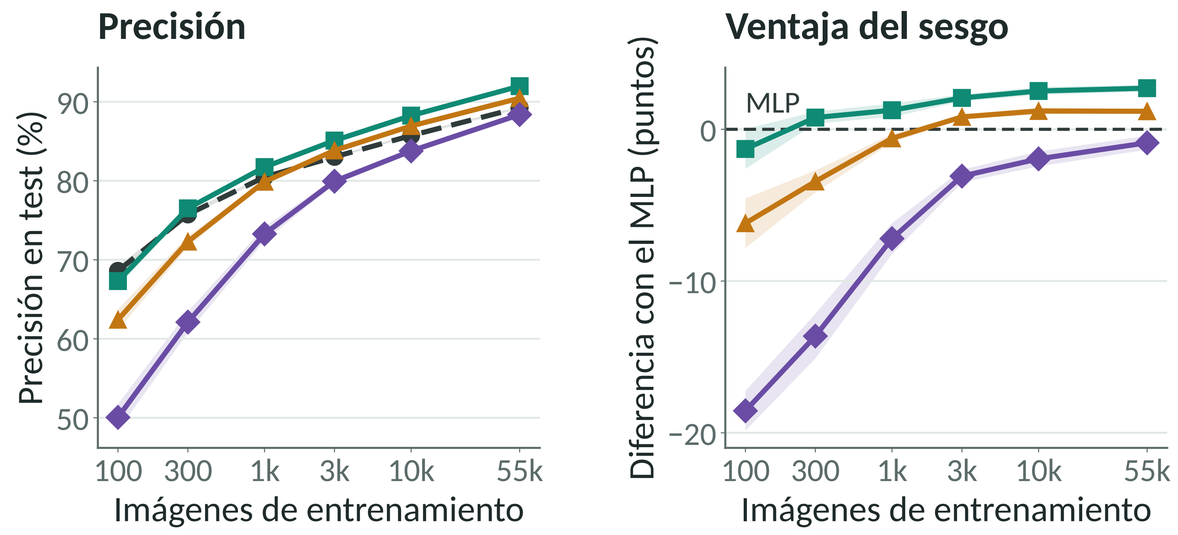


Por qué. Para el MLP, permutar la entrada es permutar las columnas de su primera capa: aprende lo mismo en otro orden (+0,3 pts). La CNN (−3,9) y la LSTM (−2,8) pierden la vecindad que suponen. El Transformer no nota los bloques, porque solo cambian de posición y sus posiciones son aprendidas.

H2 CANTIDAD DE DATOS — CONFIRMADA, CON MATIZ

«Cuantos menos datos, más importa el sesgo inductivo.»

18,6 pts separan al mejor y al peor modelo con 100 imágenes. Con 55 000, 3,6.

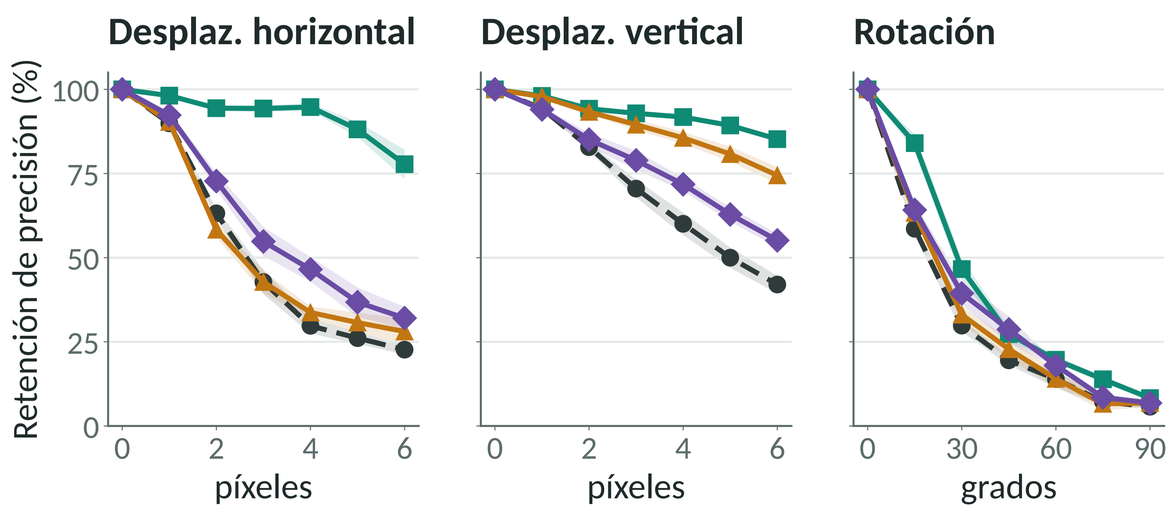


El matiz. Con pocos datos la arquitectura importa más, pero porque se hunden los sesgos débiles: el Transformer queda 18,6 puntos bajo el MLP. La CNN no gana más: con 100 imágenes queda por debajo del MLP en media, también con otros subconjuntos, y su ventaja crece con los datos, hasta +2,7. Con prendas centradas, el MLP ya funciona como un comparador de plantillas.

H3 TRANSFORMACIONES EN TEST — CONFIRMADA

«Una arquitectura generaliza a las transformaciones compatibles con su sesgo, pero no al resto.»

95 % de su precisión conserva la CNN con la prenda desplazada 4 píxeles. El MLP, el 30 %.



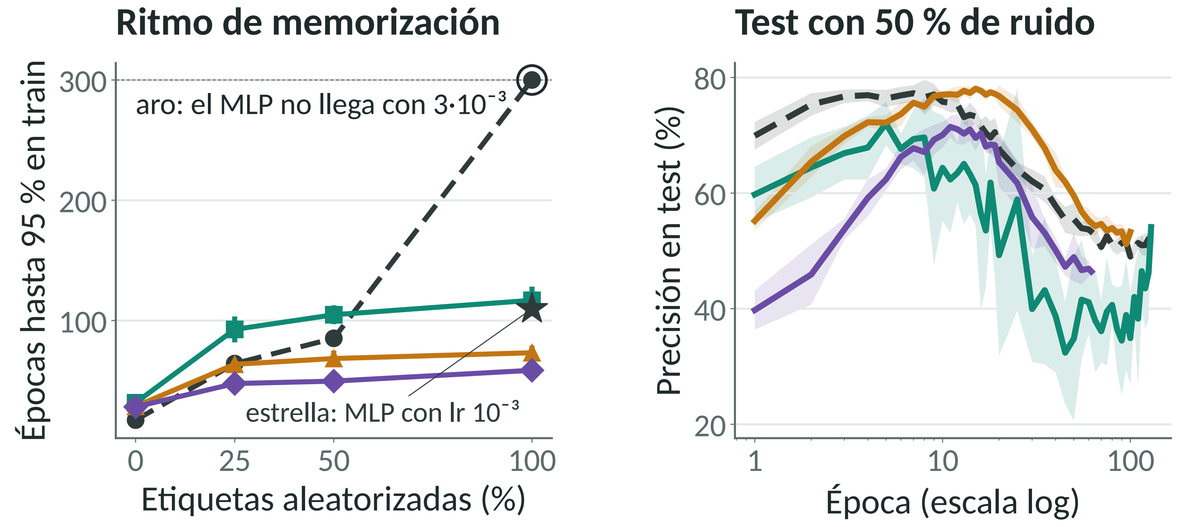
retención = precisión transformada / original

Por qué. La convolución aplica el mismo filtro en todas partes; ninguna red tiene nada que respete los giros (a 45° todas retienen menos del 30 %). La LSTM tolera el desplazamiento vertical (86 %), que para ella es un retraso de la secuencia. El Transformer, en parte (47 %): sus posiciones son absolutas.

H4 MEMORIZACIÓN — CONFIRMADA

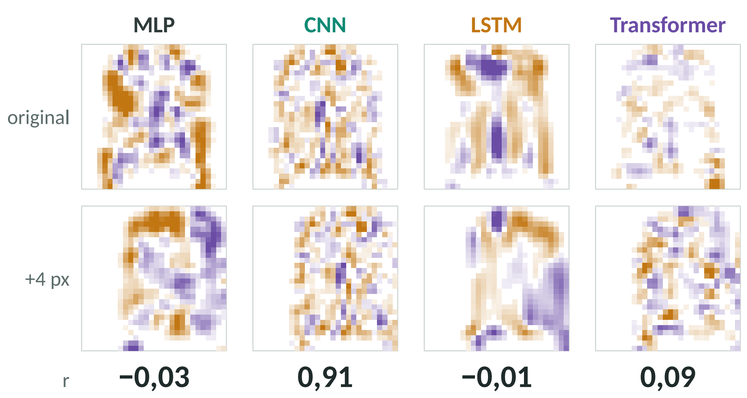
«Las cuatro arquitecturas pueden memorizar etiquetas aleatorias, pero no al mismo ritmo.»

59 → 117 épocas para memorizar el 100 % de etiquetas al azar, del Transformer a la CNN. El MLP, 110 con un learning rate menor.



Por qué. Todas tienen capacidad de sobra. El MLP se estanca con el learning rate del estudio (81 % de train) y memoriza con 10^{-3}. Con ese mismo lr para todas: Transformer 59, LSTM 81, MLP 110 y CNN 199 épocas. Todas aprenden antes lo real que el ruido.

¿Qué mira cada modelo?



Integrated Gradients de una prenda (naranja: a favor de la clase; morado: en contra), sin desplazar y desplazada 4 px. **r**: correlación entre la explicación desplazada y la original movida 4 px (300 imágenes, 5 semillas); 1 = la explicación se mueve con la prenda. Solo la de la CNN lo hace.

Predicción frente a resultado

	H1 cae al permutar	H2 supera al MLP	H3 tolera desplazar	H4 memoriza antes
MLP	✗ previsto ✗	referencia	✗ previsto ✗	referencia
CNN	✓ previsto ✓	~ **previsto ✓**	✓ previsto ✓	~ **previsto ✗**
LSTM	✓ previsto ✓	✗ **previsto ~**	~ previsto ~	~ **previsto ✗**
Transformer	~ previsto ~	✗ previsto ✗	~ **previsto ✗**	✓ **previsto ✗**

✓ sí · ~ en parte · ✗ no. Debajo, lo previsto antes de experimentar; en rojo, los fallos. **Acertamos 8 de 14**. El MLP es la referencia de H2 y H4.

Conclusiones

1. **El sesgo cuenta si encaja con los datos.** La CNN es la mejor con la imagen intacta y queda por debajo del MLP con los píxeles permutados.
2. **No sustituye a los datos.** Con 100 imágenes ninguna red supera al MLP.
3. **La invariancia la da la arquitectura.** Sin aumento de datos, nadie tolera giros.
4. **El sesgo no impide memorizar.** Las cuatro memorizan etiquetas al azar; cambia el ritmo.

Límites: un único conjunto de datos, con prendas centradas; redes pequeñas; un learning rate por modelo, constante en H4; una sola intensidad de weight decay.

Notebook reproducible con todo el código y las cifras: **sesgos_inductivos.ipynb**. Referencias: Xiao et al. 2017 (Fashion-MNIST); Zhang et al. 2017 y Arpit et al. 2017 (memorización); Dosovitskiy et al. 2021 (Transformer de visión); Sundararajan et al. 2017 (Integrated Gradients).
Durante la realización de esta actividad, se ha utilizado Claude (Anthropic) como apoyo en la programación, el análisis y la redacción.